USP · EACH · ACH2118

EP2

Classificação de clareza de respostas do e-SIC

Combinando modelos de linguagem e classificadores tradicionais



Grupo 3 · Novembro de 2026

Felipe Teixeira Rodrigues · Gabriel Fernandes Marchesano · Gabriel Alexo Rocha · Nicolas Garcia Santos

Qual é o problema?

Classificar a clareza usando apenas o texto da resposta pública.

A pergunta do projeto

Podemos estimar a clareza de uma resposta do e-SIC pelo texto?

Uma tarefa de classificação com três classes.



Desafio: não temos a pergunta original nem os anexos mencionados nas respostas.

Quais dados tínhamos?

Separar as funções dos dados evita comparar etapas diferentes.

20.092

respostas disponíveis na base original



TREINO

16.093

80,1% do total

CALIBRAÇÃO

2.027

10,1% do total

COMBINAÇÃO

1.972

9,8% do total

Teste1 · 900 respostas

Teste2 · 897 respostas

Conjuntos oficiais separados da soma de 20.092.

Dois caminhos para entender o texto

Modelos diferentes podem reconhecer sinais complementares.



CAMINHO LEXICAL

Palavras + caracteres

TF-IDF → SVM

Padrões de escrita observados na base

CAMINHO CONTEXTUAL

Tokens e contexto

NorBERTo

Representações sensíveis ao contexto

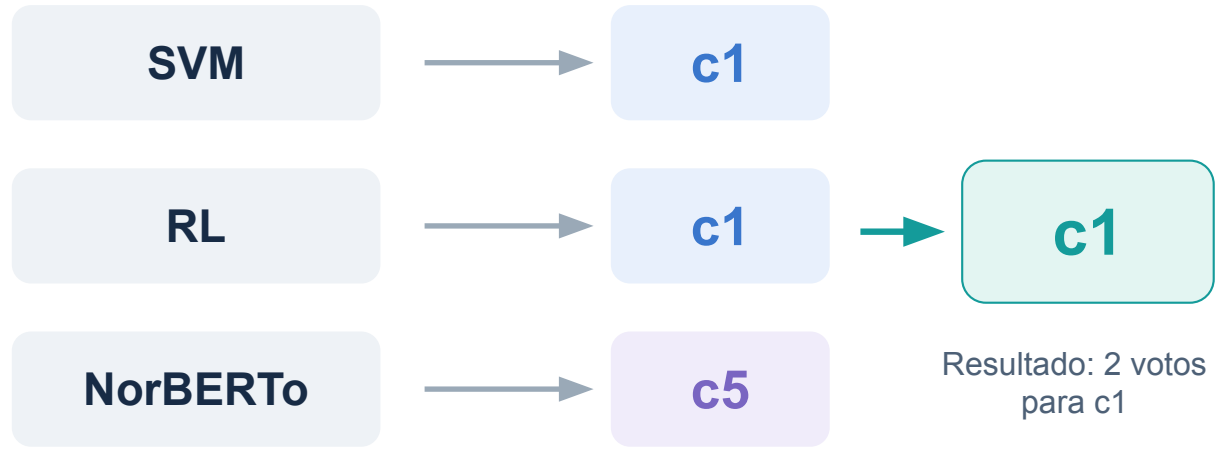
Hipótese do EP2: combinar modelos que erram de formas diferentes pode ajudar.

NorBERTo original do EP1, sem novo ajuste de pesos.

Ensemble: quando a maioria não ajuda

Votação por maioria: cada modelo tem um voto.

EXEMPLO ILUSTRATIVO



95,67%

de concordância

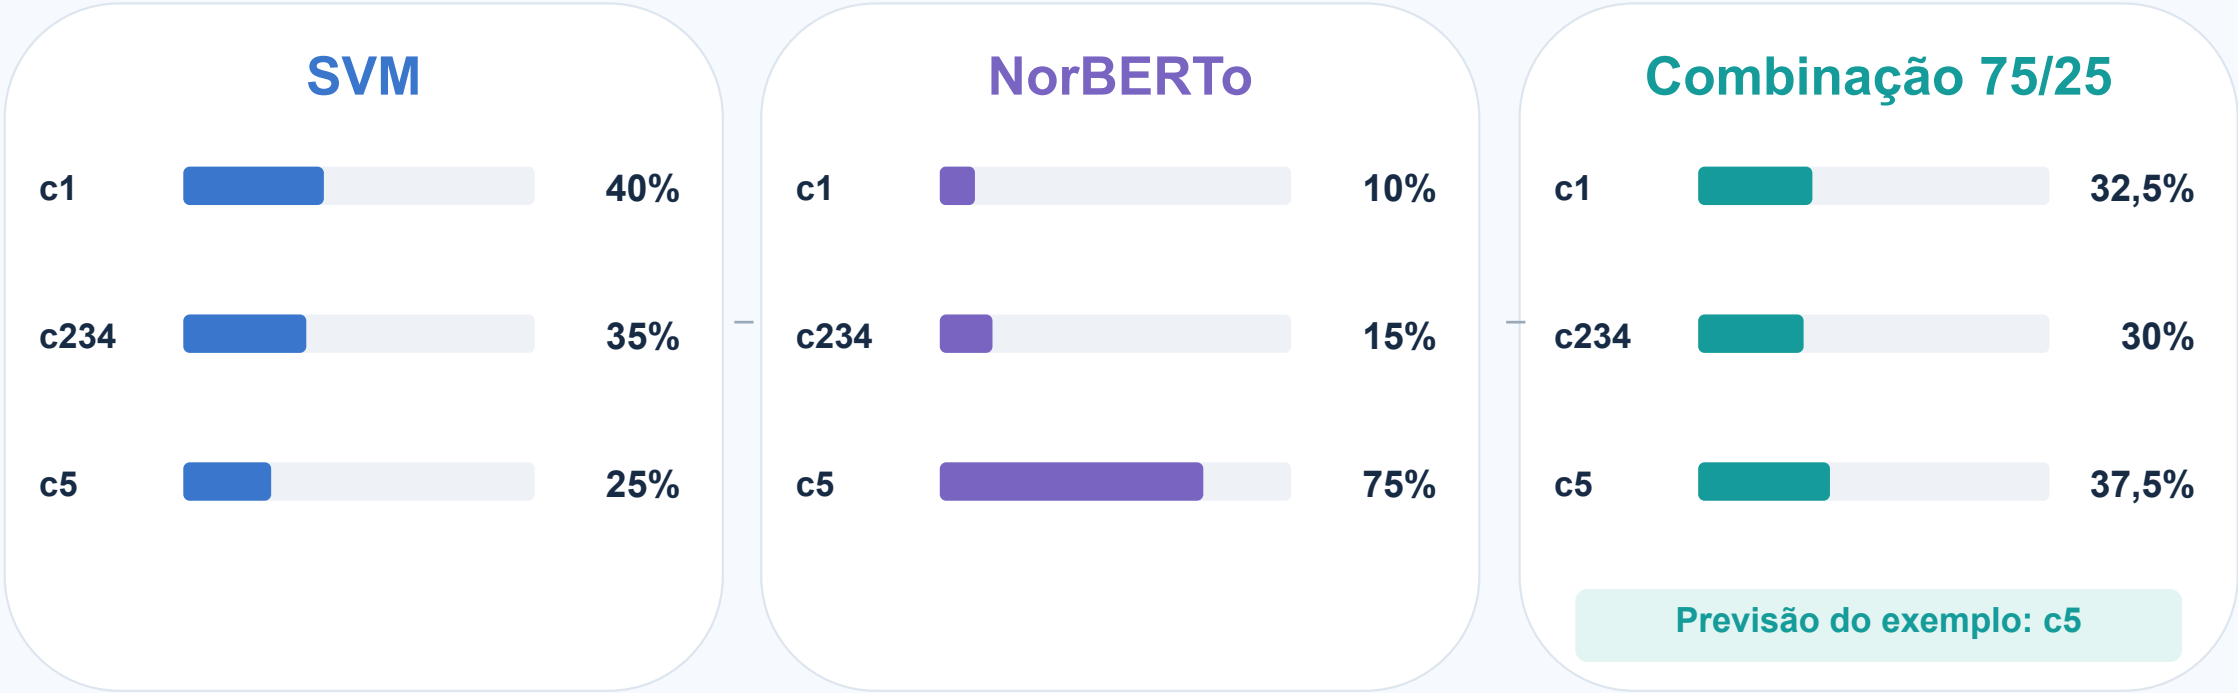
entre SVM e RL em Teste1

Maioria: 443/900 acertos (49,22%)

Mais votos não significam mais diversidade entre modelos.

Soft voting: combinando probabilidades

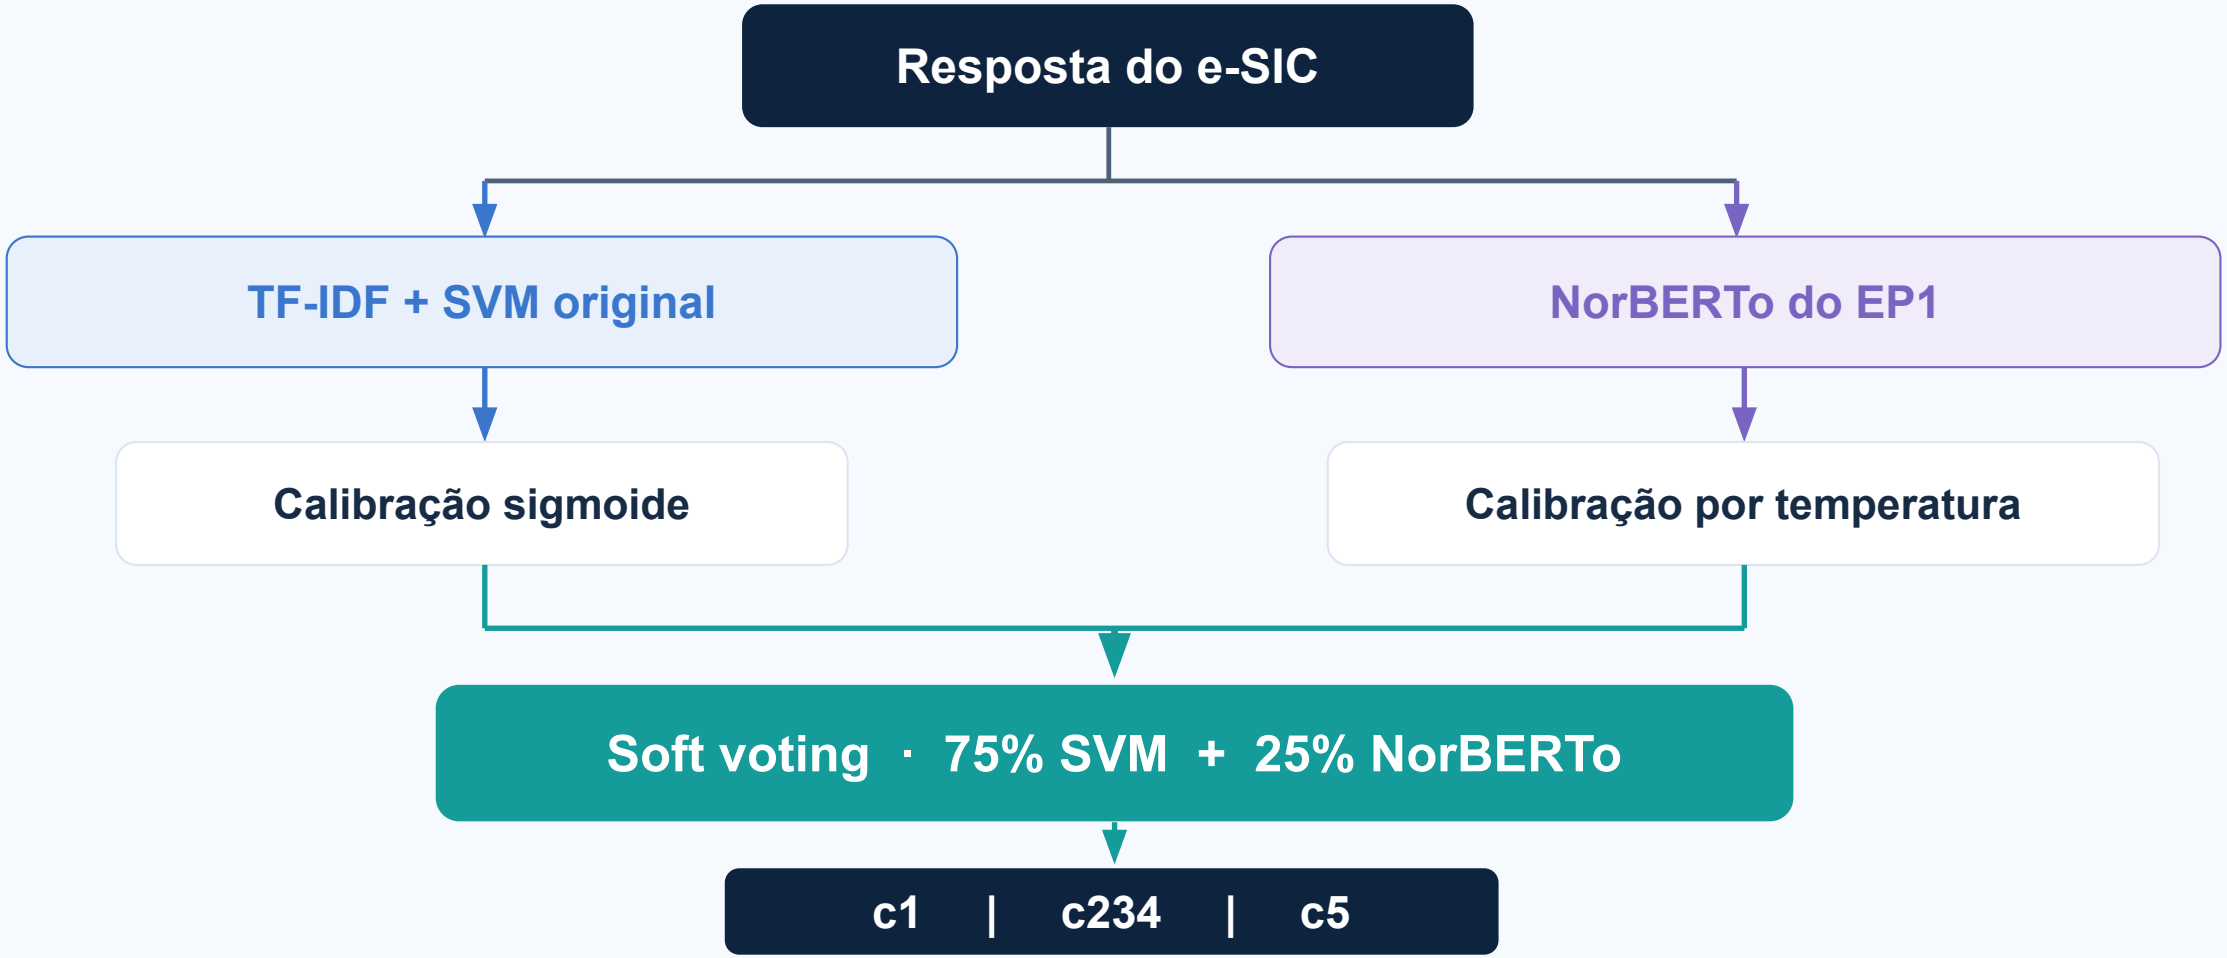
A classe vencedora pode mudar mesmo quando um modelo tem maior peso.



Probabilidade final = 75% × SVM + 25% × NorBERTo

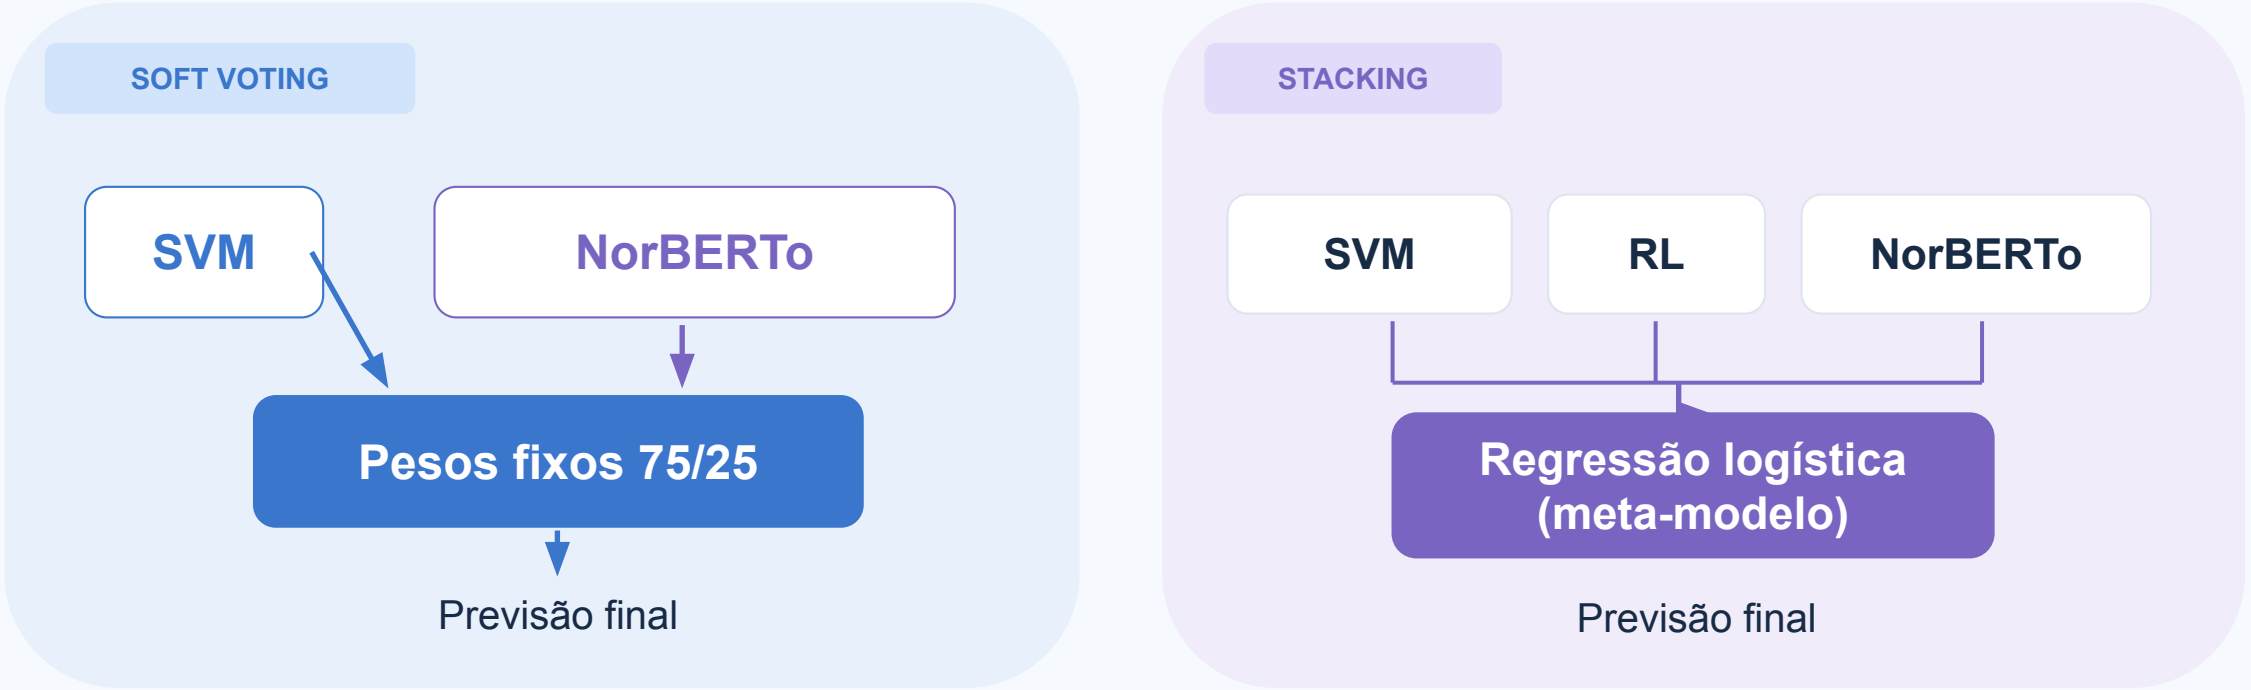
A arquitetura escolhida: calibrar + combinar

Ajustar a confiança é essencial antes de somar probabilidades.



Stacking: aprender a combinar modelos

No soft voting, pesos fixos; no stacking, um meta-modelo aprende a decisão.



40

erros corrigidos

45

acertos prejudicados

Stacking: 442/900; soft voting: 447/900. Mais flexibilidade não compensou.

Qwen: modelo maior ≠ ensemble melhor

O Qwen3-1.7B foi treinado para a tarefa e avaliado como candidato.

SVM	NorBERTo	RL	Qwen3-1.7B
75%	25%	0%	0%

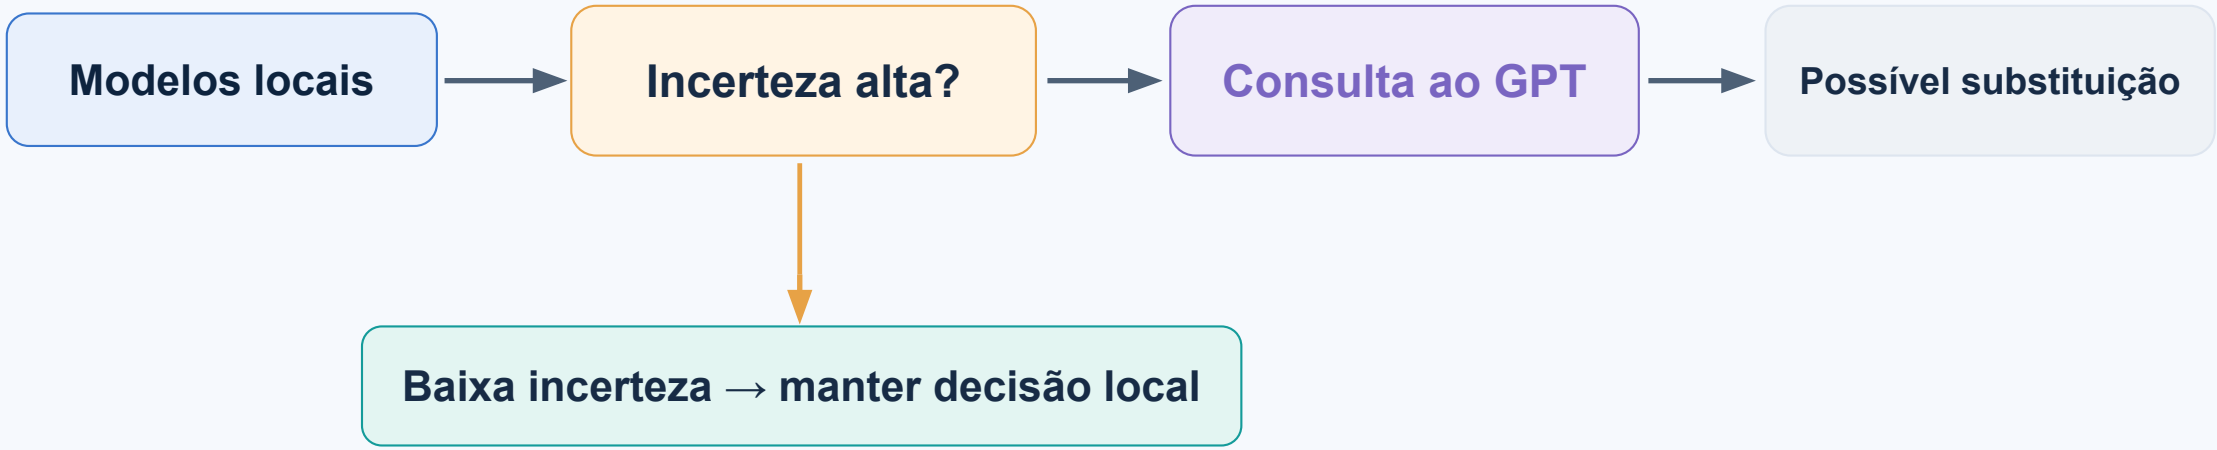
Qwen isolado: 46,00% de acurácia

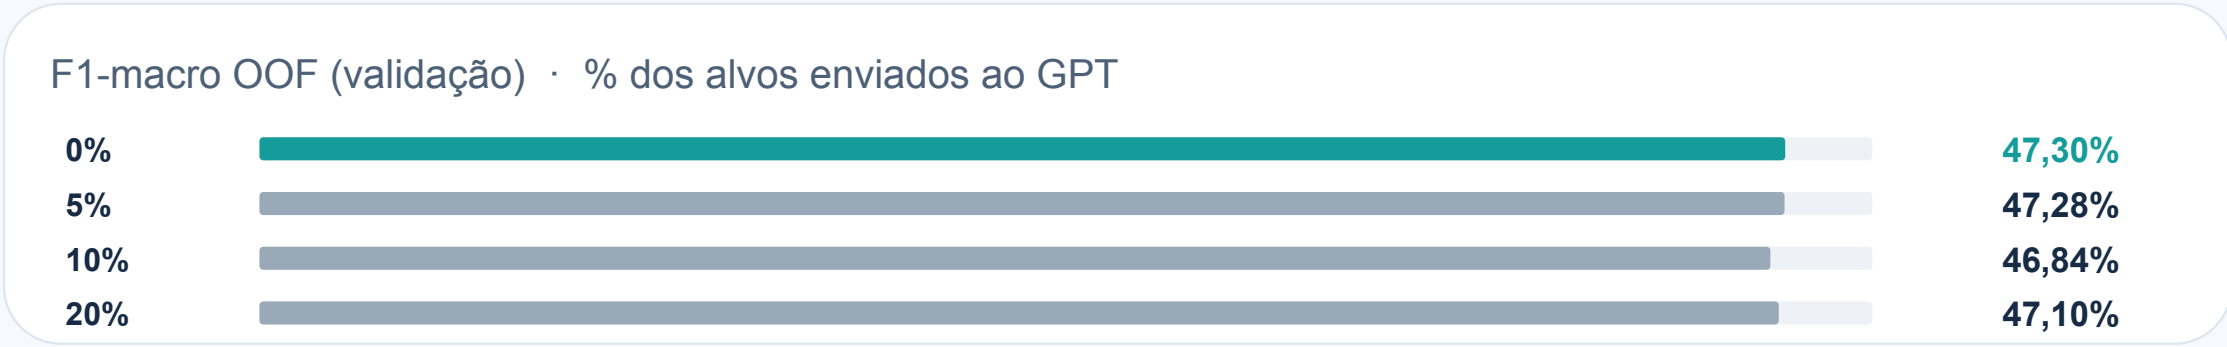
Peso final do Qwen: zero

RL e Qwen foram testados; a solução selecionada utiliza apenas SVM e NorBERTo.

GPT seletivo: consultar só os casos difíceis

A ideia era pagar o custo de uma chamada remota apenas diante de incerteza.





Nenhuma taxa positiva de intervenção superou 0% no F1-macro de validação.

RAG: recuperar exemplos melhora o GPT?

O GPT recebeu exemplos rotulados semelhantes — mas similaridade não é clareza.



PILOTO · 48 CASOS DIFÍCEIS

16 / 48
stacking local

19 / 48
melhor RAG

CONFIRMAÇÃO · 1.884 CASOS

910
stacking local

907
RAG + previsões locais (10%)

O ganho do piloto não se repetiu na confirmação.

O RAG não recuperou as perguntas originais ou os anexos ausentes da base.

Como avaliamos as alternativas?

Métricas diferentes capturam aspectos diferentes do desempenho.

ACURÁCIA

Quantas previsões foram corretas no total?

F1-MACRO

Média do F1 das três classes, com o mesmo peso para cada uma.



F1-macro em Teste1: comparação dos métodos

O soft voting foi escolhido pelo maior F1-macro observado nesta comparação.



Escala parte de zero. Pequenas diferenças devem ser interpretadas com cautela.

Onde o modelo final acerta e erra?

PREVISTA →

VERDADEIRA ↓	c1	c234	c5
c1	139	93	68
c234	74	135	91
c5	50	77	173

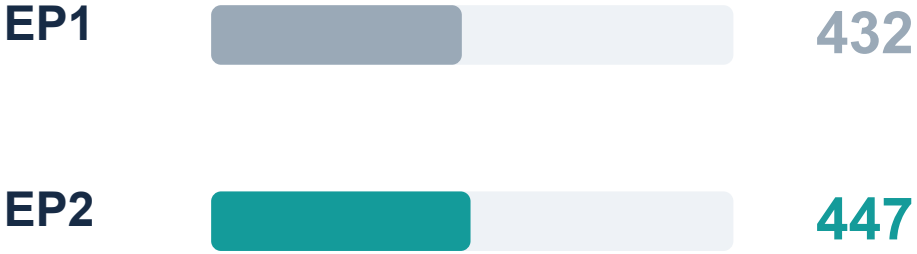
F1 c1	49,38%
F1 c234	44,63%
F1 c5	54,75%

c234 foi a classe com menor F1; c5 apresentou o maior F1.

EP2 melhorou numericamente. E estatisticamente?

Comparação pareada da entrega do EP1 com a solução final do EP2.

ACERTOS EM TESTE1 · 900 RESPOSTAS



+15 acertos · de 48,00% para 49,67%

COMPARAÇÃO PAREADA EP1 × EP2

	EP2 acerta	EP2 erra
EP1 acerta	347	85
EP1 erra	100	368

McNemar exato: p = 0,3033 → diferença não significativa a 5%

100 casos corrigidos e 85 prejudicados; não significativo não significa equivalência.

Por que esta tarefa é tão difícil?

Dois exemplos reais mostram o limite de classificar o texto isolado.

CASO REAL · LINHA 77

“Prezado Senhor.”

Rótulo de referência	c5
Previsão do ensemble	c1

Uma saudação sem informação substantiva.

CASO REAL · LINHA 693

“Sua resposta segue em anexo.”

Rótulo de referência	c1
Previsão do ensemble	c5

O anexo citado não está disponível.

Perguntas originais e anexos ausentes dificultam avaliar a suficiência das respostas.

Os rótulos de referência não foram alterados; os exemplos não provam erro de anotação.

CONCLUSÃO

A solução mais simples foi a escolhida.

Soft voting com probabilidades calibradas

75% SVM original — **25%** NorBERTo EP1

Teste1: 49,67% de acurácia · 49,58% de F1-macro

Maioria · Stacking · Qwen · GPT seletivo · RAG

O ganho de 15 acertos ante o EP1 não foi estatisticamente significativo.